

基于 YOLO 与动态正交注意力的暴力行为检测算法

吴家明, 林可, 冯楠, 仇思思, 文勇

(广西民族大学 人工智能学院, 广西南宁 530006)

摘要: 针对现有基于深度学习的暴力行为检测方法存在时空信息建模不充分, 复杂场景鲁棒性差的问题, 提出了一种基于 YOLO 和混合注意力机制的暴力行为检测算法。该算法将正交通道注意力 OrthoNets 集成到 YOLO 主干网络的 C2f 模块中, 使用随机初始化的正交滤波器压缩特征空间信息, 确保特征多样性, 便于后续提取。并在 Neck 端融入通道空间混合注意力模块 CBAM, 用于增强网络的特征表示能力。实验结果表明, 该算法在具有多样化内容和复杂环境的 RWF-2000 数据集上精确率、召回率、平均精度分别达到了 91.25%、95.6% 和 87.5%, 在精度指标和鲁棒性上均优于目前最先进的同类算法, 充分证明了其有效性。

关键词: 深度学习; 暴力行为检测; YOLO; 注意力机制

中图分类号: TP391.4

文献标识码: A

文章编号: 2096-4706 (2026) 10-0061-05

Violence Detection Algorithm Based on YOLO and Dynamic Orthogonal Attention Mechanism

WU Jiaming, LIN Ke, FENG Nan, CHOU Sisi, WEN Yong

(School of Artificial Intelligence, Guangxi Minzu University, Nanning 530006, China)

Abstract: Aiming at the problems of inadequate spatio-temporal information modeling and poor robustness in complex scenes in existing violence detection methods based on Deep Learning, a violence detection algorithm based on YOLO and hybrid Attention Mechanism is proposed. The algorithm integrates orthogonal channel attention OrthoNets into the C2f module in YOLO backbone network, and uses randomly initialized orthogonal filters to compress feature space information, ensuring feature diversity for subsequent extraction. The channel space mixed attention module CBAM is integrated into the Neck end to enhance the network feature representation capability. The experimental results demonstrate that the algorithm achieves accuracy, recall, and average precision of 91.25%, 95.6%, and 87.5%, respectively, on the RWF-2000 dataset characterized by diverse content and complex environments. It outperforms the most advanced algorithms of the same kind at present in both accuracy metrics and robustness, fully validating its effectiveness.

Keywords: Deep Learning; violence detection; YOLO; Attention Mechanism

0 引言

暴力行为检测作为视频分类领域中聚焦异常行为识别的核心研究方向, 不仅是计算机视觉技术落地智慧安防、公共安全治理的关键支撑, 更承载着从“被动监控响应”向“主动风险预警”转型的核心诉求, 其核心目标在于从连续视频流中自动辨识具有攻击性、破坏性或危害性的异常行为模式, 确保检测结果的精准性与实用性^[1]。

以往的暴力行为检测大多基于传统机器学习方法, 如鹿天然等人^[2]提出采用改进的稠密轨迹算法,

通过提取视频中运动目标的稠密光流轨迹, 结合轨迹的方向、速度等动态特征构建行为描述子, 再利用支持向量机 (SVM) 的核函数机制完成暴力与非暴力行为的二分类。随着计算机硬件水平与大规模视频数据的可用性提升, 基于深度学习的暴力检测方法凭借“端到端特征学习”能力实现了性能突破, 成为当前研究主流。这类方法通过神经网络自动挖掘视频的深层时空特征, 显著提升了对复杂场景的适应性。Fath 等人^[3]提出了基于 3DCNN 的三层端到端深度学习暴力检测框架, 采用 3D 卷积核直接建模视频的时空联合特征, 为时序行为建模提供了新范式; Dinesh 等人^[4]提取局部 HOG 特征并将其输入到双向长短期记忆 (LSTM) 中以检索信息, 一定程度上缓解了单一静态特征对动态信息的丢失问题; 李冠等人^[5]人提出一种将 YOLO 和 ConvLSTM 相结合的混合神经网络, 进一步融合了目标检测与时序建模优势。

收稿日期: 2025-11-01

基金项目: 广西民族大学自治区级大学生创新创业训练计划项目 (S202310608294); 广西民族大学研究生教育创新项目 (gxzmzu-chxs2024302)

上述方法表明,如今暴力行为检测这一研究方向已经取得了很大进展,但是在实际应用中仍然存在时空信息建模不充分、复杂场景鲁棒性差的问题。为了能更加适配实际应用场景,本文提出了一种基于 YOLO 和混合注意力机制的暴力行为检测算法,通过引入正交通道注意力机制 (OrthoNets) 进行特征解耦,增强时空表达多样性,并在后续加入了通道空间混合注意力模块 (CBAM) 对上下文进行建模来抑制干扰,提高模型鲁棒性。

1 本文模型

YOLOv8 是 Ultralytics 团队^[6]于 2023 年推出的 YOLO 系列最新版本,在继承前代优势的基础上,通过全面的结构优化和功能扩展,成为当前目标检测领域的标杆性工具。YOLOv8 具备实时检测能力与灵活的架构设计,对比以往的 YOLO 模型,其在保持精度的同时,更加轻量化,被广泛运用于目标检测、实例分割、图像分类、姿态估计等任务。根据网络的深度和特征图的大小,YOLOv8 提供了五种不同规模的版本: n、s、m、l、x,以满足从边缘设备到高性能服务器的需求^[7]。

1.1 改进 YOLOv8

为提高暴力行为检测算法对视频序列中时空信息的有效捕捉能力,并增强其在复杂场景下的鲁棒性,本文提出了一种基于轻量化模型 YOLOv8n 改进的暴力行为检测算法——YOLOv8-ON。针对暴力行为检测中“关键动作特征易被背景干扰”“多尺度目标特征融合不充分”“类别不平衡导致分类精度不足”等核心痛点,YOLOv8-ON 从特征提取、特征融合及损失优化三个维度进行了针对性改进。如图 1 所示,YOLOv8-ON 的具体改进包括:针对 YOLOv8 易受复杂背景干扰,导致对暴力行为关键区域的特征响应不足问题,在 Backbone 中引入 OrthoNets 注意力模块^[8],通过构建特征通道间的正交化映射关系,抑制冗余特征,增强关键特征的聚焦能力;在 Neck 网络中引入通道空间混合注意力模块 CBAM,实现对融合特征的精细化筛选,优化多尺度特征融合效率;以及针对原有的分类损失函数在处理此类样本时,易因多数类的主导作用导致模型对少数类的判别能力不足,出现漏检或误判的问题,使用 SLSLoss^[9]替代 YOLOv8 原分类损失函数,引入标签平滑机制与难样本挖掘策略,提升类别不平衡场景下的分类鲁棒性。




图 1 总体模型图

1.2 C2f-ON 模块

原始 YOLOv8 在多目标检测和小目标检测中均有出色表现, 但更偏向于多目标检测^[10]。暴力行为检测常涉及人体局部动作, 这些目标在图像中占比小, 在小目标场景中, OrthoNets 能更精准地捕捉细微动作特征。

OrthoNets 的核心创新在于利用正交滤波器对通道进行压缩和注意力加权。正交性确保滤波器从特征空间的不同子空间提取信息, 避免冗余, 显著提升特征多样性。实现过程如图 2 所示: 在 State0 阶段, 如式 (1) 所示, 一组随机初始化的滤波器 $\{w_1, w_2, \dots, w_n\}$ 通过 Gram-Schmidt 正交化得到正交滤波器 $\{v_1, v_2, \dots, v_n\}$, 其中 $\text{proj}_{v_i}(w_i)$ 是 w_i 在 v_i 上的投影。

$$v_i = w_i - \sum_{j=1}^{i-1} \text{proj}_{v_j}(w_i) v_j \quad (1)$$

输入 X 通过卷积操作之后初步提取特征, 之后的阶段, 如式 (2)、式 (3) 所示, 正交滤波器对每个通道的特征进行卷积, 之后将空间信息压缩为单个通道后将压缩的特征送入多层感知器和 Sigmoid 函数, 生成通道注意力向量, 最后再将注意力向量与输入特征向量相乘, 得到加权输出特征。

$$F_{\text{ortho}}(X)_c = \sum_{h=1}^H \sum_{w=1}^W v X \quad (2)$$

$$\text{Output} = \text{Conv}(X) + \text{Attention}(F_{\text{ortho}}(X)) \quad (3)$$




图 2 OrthoNets 结构图

1.3 CBAM 模块

YOLOv8 的 Neck 网络主要功能是进行多尺度特征融合, 以增强模型对不同尺度目标的检测能力。但传统的 Neck 结构中, 融合后的多尺度特征中包含大量干扰信息, 影响后续检测精度, 并且对重要区域或关键特征的专注能力有限, 不能很好地突出目标区域; 而后续 Head 网络部分主要负责分类和回归预测, 其性能高度依赖于 Neck 输出的特征图质量。因此, 我们在 Neck 中引入了通道 - 空间混合注意力模

块 CBAM 来引导网络关注更有用的特征信息, 提升融合特征的质量。

具体实现如式 (4) 所示, 其中 $Mc()$, $Ms()$ 分别表示通道和空间注意力图。输入特征 F_1 先经过通道注意力模块, 之后与原始 F_1 相乘得到中间特征 F_2 , 之后 F_2 再经过空间注意力模块, 并与原始 F_2 相乘得到最终输出特征 F_3 。

$$F_2 = F_1 \otimes Mc(F_1), F_3 = F_2 \otimes Ms(F_2) \quad (4)$$

2 实验结果

本文的实验在 Linux 操作系统上进行, 该系统配备主频为 3.70 GHz 的 CPU AMD Ryzen 5 7500F、NVIDIA RTX 4080 Super GPU、32 GB RAM 和 1 TB 固态硬盘。编程语言为 Python 3.9, 使用 PyTorch 1.13.0 深度学习框架。GPU 加速由 CUDA 12.6 和 CUDNN 8.4.1 提供。为了缩短网络训练时间, 采用了冻结方法, 初始将冻结向量主干训练的学习率设置为 0.001, 批大小为 16, 动量设置为 0.927。解冻阶段后, 学习率保持恒定 0.001, 批大小和动量保持不变, 共进行 120 次迭代。

2.1 评价指标

为客观地验证本文所提暴力行为检测方法的性能, 结合目标检测任务的评价核心与暴力行为检测的实际应用需求, 本文选取精确率 (Precision, P)、平均精度均值 (mean Average Precision, mAP) 和召回率 (Recall, R) 作为核心评价指标, 三者从不同维度量化模型的检测效能, 形成互补的评价体系。

精确率 (P): 精确率聚焦于模型“预测准确性”维度, 核心衡量模型检测出的预测为暴力行为的样本中, 真正属于暴力行为的样本占比, 直接反映模型对非暴力行为的误报率。具体如式 (5) 所示, 通过计算真正例 (TP) 与所有预测为正例 (TP+FP) 的比值得出的。

$$P = \frac{TP}{TP+FP} \quad (5)$$

平均精度均值 (mAP): 暴力行为检测本质上属于多类别目标检测任务, 单一类别的检测性能无法全面反映模型的综合能力。平均精度均值 (mAP) 通过独立计算各检测类别的平均精度 (AP), 并采用算术平均法进行全局聚合, 从而量化模型在多类别目标检测任务中的综合效能。其公式如式 (6) 所示, 其中 k 表示类别总数:

$$AP = \int_0^1 P(R) dR, mAP = \frac{\sum_{i=1}^k AP_i}{k} \quad (6)$$

召回率 (R): 衡量所有真实发生的暴力行为中,

被成功检测出来的暴力行为占比。具体如式 (7) 所示, 通过计算真正例 (TP) 与所有真实为正例 (TP+FN) 的比值得出。其中, TP 指真实为暴力行为且被正确检测为暴力行为的样本, FN 指真实为暴力行为但被错误检测为非暴力行为的样本。

$$R = \frac{TP}{TP+FN} \quad (7)$$

2.2 数据集

本文在 RWF-2000 数据集上进行评估, RWF-2000 是一个专门用于暴力检测任务的大规模监控视频数据库, 该数据集共包含 2000 段未经刻意剪辑的真实监控视频, 采用均衡化数据划分策略, 其中暴力行为视频与非暴力日常场景视频各 1000 段, 确保评估过程中无类别偏倚影响。视频来源覆盖校园、城市街道、商场、车站、社区广场等多类高频监控场景, 场景多样性极强; 同时, 视频的分辨率、光照条件、拍摄角度均还原了实际监控设备的工作状态, 进一步提升了评估的真实性。

2.3 对比实验

为直观验证本方法性能, 在 RWF 数据集上与 CNN-LSTM-IOT(2021)^[11]、VD-Net(2022)^[12]、TL(2023)^[13]、VBA-net(2024)^[14] 四种近年主流方法进行对比, 具体结果如表 1 所示。结果表明, 本方法在召回率上比次优方法提升 0.6 个百分点, 精确率增幅达 2.25 个百分点, 平均精度均值提升 0.7 个百分点, 综合反映出本方法在检测准确性与稳健性上的优势, 进一步验证了所提技术改进的有效性。具体运行结果如图 3 所示, 该图通过三层可视化直观呈现了 YOLOv8-ON 在暴力行为检测场景中的表现细节, 进一步印证了算法改进的实际效果: 第一层 (原图) 展示了典型的暴力行为场景, 包含复杂动态元素; 第二层 (检测结果) 呈现了 YOLOv8-ON 的输出结果: 算法通过边界框准确框定了所有暴力行为发生的核心区域; 第三层 (注意力可视化图) 以热力图形式展示了模型的注意力聚焦区域, 直观揭示了改进模块的作用机制: 热力图中高响应区域 (红色 / 黄色区域) 集中于暴力行为的关键特征点。

表 1 与主流算法比较结果 单位: %

方法	R	P	mAP
CNN-LSTM-IOT(2021)	79.80	73.55	70.20
VD-Net(2022)	90.50	88.20	85.60
TL(2023)	87.20	85.00	82.30
VBA-net(2024)	95.00	89.00	86.80
Our	95.60	91.25	87.50



图 3 运行结果与注意力可视化图

2.4 消融实验

为验证各改进模块的独立作用及协同效果, 消融实验以原始 YOLOv8n 为基础模型, 逐步添加 OrthoNets 注意力模块、CBAM 模块及 SLSLoss, 对比不同组合下的性能指标。

1) 仅在 Backbone 中引入 OrthoNets 时, 模型召回率从 90.20% 提升至 93.50%, 精确率从 85.50% 提升至 88.30%, mAP 提升 2.6 个百分点, 这表明 OrthoNets 通过抑制背景冗余特征、增强暴力行为关键区域的特征响应, 有效提升了模型性能。

2) 仅在 Neck 中引入 CBAM 时, 模型召回率提升 1.9 个百分点, 精确率提升 2.1 个百分点, mAP 提升 1.8 个百分点。结果体现了 CBAM 对多尺度特征的精细化筛选能力, 通过通道与空间注意力的双重作用, 强化了不同尺度暴力行为的融合特征, 尤其对小目标或遮挡场景下的特征识别有显著增益。

3) 仅替换损失函数为 SLSLoss 时, 模型精确率提升最为明显, 提升 3.6 个百分点, 召回率提升 1.6 个百分点, mAP 提升 1.4 个百分点。这印证了 SLSLoss 在解决类别不平衡问题上的优势: 通过标签平滑与难样本挖掘, 模型对少数类及边界样本的判别能力增强, 减少了因多数类主导导致的误判, 显著提升了分类精度。

4) 当三个模块共同作用时, 召回率、精确率、mAP 分别达到 95.60%、91.25%、87.50%, 较基础模型分别提升 5.4 个百分点、5.75 个百分点、5.4 个百分点。这表明 OrthoNets (强化特征提取)、CBAM (优化特征融合) 与 SLSLoss (提升分类鲁棒性) 形成了端到端的协同增益, 共同推动模型性能达到最优, 进一步验证了所提改进策略的合理性与有效性。具体消融实验结果表 2 所示。

表 2 消融实验结果 单位: %

方法	R	P	mAP
YOLOv8n	90.20	85.50	82.10
YOLOv8n+OrthoNets	93.50	88.30	84.70
YOLOv8n+CBAM	92.10	87.60	83.90
YOLOv8n+SLSLoss	91.80	89.10	83.50
YOLOv8-ON	95.60	91.25	87.50

3 结 论

本文提出的暴力行为检测算法YOLOv8-ON,是以YOLOv8为基础框架,通过创新性引入混合注意力机制构建的高效检测模型。该算法针对暴力行为检测中时空特征碎片化、复杂场景干扰强等核心挑战,在网络架构层面进行关键优化。在Backbone中引入OrthoNets注意力模块以及在Neck网络中引入通道空间混合注意力模块CBAM,有效提升了对时空信息的利用效率和模型在复杂场景下的鲁棒性。未来,将进一步探索将本算法与多模态信息融合,利用不同模态的互补性提升极端场景下的检测可靠性;并与更先进的自监督学习技术相结合,减少对人工标注的依赖,同时提升模型在校园、地铁、乡村等多样化场景中的自适应能力。

参考文献:

[1] MUMTAZ N, EJAZ N, HABIB S, et al. An Overview of Violence Detection Techniques: Current Challenges and Future Directions [J]. Artificial intelligence review, 2023, 56 (5): 4641-4666.

[2] 鹿天然,于凤芹,杨慧中,等.基于显著性检测和稠密轨迹的人体行为识别[J].计算机工程与应用,2018,54(14): 163-167, 179.

[3] FATH U M U, AMIN U, KHAN M, et al. Violence Detection Using Spatiotemporal Features with 3D Convolutional Neural Network [J]. Sensors, 2019, 19 (11): 2472.

[4] DINESH J S R, FENIL E, GUNASEKARAN M, et al. Real Time Violence Detection Framework for Football Stadium Comprising of Big Data Analysis and Deep Learning Through Bidirectional LSTM [J]. Computer Networks, 2019, 151: 191-200.

[5] 李冠,庞玉琳,田坤.基于YOLO和ConvLSTM混合神经网络的暴力视频检测[J].计算机应用与软件,2023,40(11): 233-240.

[6] 王斌,徐洪华,孙兜成,等.基于YOLOv8算法改进的小目标交通标志检测[J].计算机应用,2024,44(S2): 274-279.

[7] SOHAN M, SAI RAM T, RAMI REDDY C V. A

Review on Yolov8 and Its Advancements [C]// International Conference on Data Intelligence and Cognitive Informatics. Singapore: Springer, 2024: 529-545.

[8] SALMAN H, PARKS C, SWAN M, et al. Orthonets: Orthogonal Channel Attention Networks [C]// 2023 IEEE International Conference on Big Data (BigData). Sorrento: IEEE, 2023: 829-837.

[9] LIU Q, LIU R, ZHENG B, et al. Infrared Small Target Detection with Scale and Location Sensitivity [C]// Proceedings of the IEEE/CVF 2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle: IEEE, 2024: 17490-17499.

[10] 董红召,林少轩,余翊妮.交通目标YOLO检测技术的研究进展[J].浙江大学学报(工学版),2025,59(2): 249-260.

[11] ALDAHOUL N, KARIM H A, DATTA R, et al. Convolutional Neural Network Long Short Term Memory Based IoT Node for Violence Detection [C]// 2021 IEEE International Conference on Artificial Intelligence in Engineering and Technology (IICAIET). New York: IEEE, 2021: 1-6.

[12] ULLAH F U M, MUHAMMAD K, HAQ I U, et al. AI-assisted edge Vision for Violence Detection in IoT-based Industrial Surveillance Networks [J]. IEEE Transactions on Industrial Informatics, 2022, 18 (8): 5359-5370.

[13] HUSZÁR V D, ADHIKARLA V K, NEGYESI I, et al. Toward fast and Accurate Violence Detection for Automated Video Surveillance Applications [J]. IEEE access, 2023, 11: 18772-18793.

[14] 李金成,闫睿鹭,代雪晶.基于改进注意力机制与VGG-BiLSTM的暴力行为检测[J].现代电子技术,2024,47(21): 131-138.

作者简介: 吴家明(2000—),男,汉族,广东梅州人,硕士研究生,研究方向:图像处理与智能系统;林可(2003—),男,汉族,广西南宁人,本科,研究方向:图像处理与智能系统;冯楠(2002—),女,满族,河北承德人,本科,研究方向:图像处理与智能系统;仇思思(2001—),女,汉族,广西钦州人,本科,研究方向:图像处理与智能系统;通信作者:文勇(1969—),男,壮族,广西南宁人,副教授,硕士,研究方向:图像处理与智能系统。

(上接60页)

[7] CHEN D P, CHEN R X, ZHANG S L, et al. MLLM-as-a-judge: Assessing Multimodal LLM-as-a-judge with Vision-language Benchmark [J/OL]. arXiv:2402.04788 [cs.CL]. (2024-02-07). <https://arxiv.org/abs/2402.04788>.

[8] CHENG P Z, WU Z, WU Z R, et al. OS-Kairos: Adaptive Interaction for MLLM-Powered GUI Agents [J/OL]. arXiv:2503.16465 [cs.HC]. (2025-02-26). <https://arxiv.org/abs/2503.16465>.

[9] WANG Z W, CHEN W Z, YANG L Y, et al. MP-

GUI: Modality Perception with MLLMs for GUI Understanding [C]// 2025 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Nashville: IEEE, 2025: 29711-29721.

[10] DEKA B, HUANG Z F, FRANZEN C, et al. Rico: A Mobile APP Dataset for Building Data-driven Design Applications [C]// UIST'17: Proceedings of the 30th Annual ACM Symposium on User Interface Software and Technology. Québec City: ACM, 2017: 845-854.

作者简介: 吕桂州(2001—),男,汉族,安徽滁州人,硕士研究生在读,研究方向:GUI自动化测试。