

# 视频中暴力行为的检测

郑林辉, 刘 琼\*

(北京信息科技大学自动化学院, 北京 100192)

**摘 要:** 现有暴力视频检测模型存在计算复杂度高、参数量大的问题。文章提出了创新的解决方案, 通过引入可分离卷积技术, 重新设计了浅层与深层特征的集成机制, 避免了冗余信息的干扰。同时, 该方案采用 Darknet 架构作为基础模型, 利用其简洁高效的设计, 能够显著提升训练效率。实验结果表明, 该方法在 Fight Detection 和 RWF-2000 数据集上的准确率分别达到 99.15% 和 98.81%, 较次优算法分别提高了 0.53% 和 0.97%, 每秒十亿次浮点运算次数 (Giga Floating Point Operations Per Second, GFLOPs) 为 90, 验证了该方法在暴力视频检测任务中的高效性和鲁棒性。

**关键词:** 暴力视频检测; 可分离卷积技术; 特征集成机制

**中图分类号:** TP391.41    **文献标识码:** A    **文章编号:** 1003-9767(2025)17-001-04

## Detection of Violence in Video

ZHENG Linhui, LIU Qiong\*

(College of Automation, Beijing Information Science & Technology University, Beijing 100192, China)

**Abstract:** Existing violent video detection models suffer from high computational complexity and large number of parameters. The paper proposes an innovative solution. By introducing the separable convolution technique, the integration mechanism of shallow and deep features is redesigned to avoid redundant information interference. Meanwhile, the Darknet architecture is adopted as the base model, which can significantly improve the training efficiency by utilizing its concise and efficient design. The experimental results show that the method achieves 99.15% and 98.81% accuracy on Fight Detection and RWF-2000 datasets, respectively, which are 0.53% and 0.97% higher than the suboptimal algorithm, with a computational complexity of 90 giga floating point operations per second (GFLOPs), verifying the efficiency and robustness of the method in violent video detection tasks.

**Keywords:** violent video detection; separable convolution technique; integration mechanism of features

### 0 引 言

暴力行为检测是通过分析视频中人、物的行为来识别潜在的暴力事件, 是计算机视觉领域中的一个重要研究方向。当前的主流方法是整合卷积神经网络 (Convolutional Neural Network, CNN) 与长短期记忆网络 (Long Short-Term Memory, LSTM), 协同处理 RGB 图像和运动表征

图像。Dong 等<sup>[1]</sup>采用二维 CNN 提取空间特征, 并利用 LSTM 进行时间序列建模, 实现暴力识别。Sudhakaran 等<sup>[2]</sup>则基于卷积长短期记忆网络 (Convolutional Long Short-Term Memory, ConvLSTM) 架构, 从帧差中提取时空特征, 利用 CNN 代替全连接层, 降低了计算量。Liang 等<sup>[3]</sup>利用注意力机制减少背景干扰。Islam 等<sup>[4]</sup>不仅采用

收稿日期: 2025-04-17

基金项目: 国家自然科学基金项目“安检开放环境下的违禁品自动分割与识别研究”(项目编号: 62302051)。

作者简介: 郑林辉, 男, 硕士。研究方向: 模式识别、图像分类。

通信作者: 刘琼, 女, 博士, 教授。研究方向: 人工智能、数据挖掘。

平均帧背景抑制技术,还提出了可分离卷积技术,以进一步减小计算量。Hanson 等<sup>[5]</sup>提出双向卷积长短期记忆神经网络(Bidirectional Convolutional LSTM, BiConvLSTM)架构,通过双向 LSTM 结合前向和后向时间信息提高识别能力。Asad 等<sup>[6]</sup>提出的帧级暴力识别方法,采用双 VGG16 网络分别提取帧间的低级和高级特征,再结合 LSTM 进行时序建模,以提高整体的特征表示能力。此外, Traoré 等<sup>[7]</sup>利用双向门控循环单元来提升识别效率。这些方法在特征提取和时序建模方面各有侧重,共同推动了该领域的技术发展。目前,已有算法随着模型深度的加深和复杂度的提高,计算复杂度不断增加。为降低模型的运算量和计算复杂度,本文选用 Darknet 网络,基于可分离卷积设计了 CDPP (Convolution-Depthwise-Pointwise-

Pointwise)模块,在进一步提取空间特征的同时减小计算复杂度,并通过特定的特征转换机制,将提取到的特征适配为 LSTM 模块的输入格式。

## 1 此文方法

### 1.1 模型框架

此文设计了一个新颖的深度可分离卷积模块,模型的主体架构如图 1 所示。将第  $T$  帧和第  $T+1$  帧的视频帧依次输入 Darknet 模型,提取浅层特征并按顺序拼接,同时生成深层特征并按顺序拼接。拼接后的浅层特征和深层特征分别输入 CDPP 模块,统一形状和维度。处理完所有视频帧后,收集所有浅层和深层特征,按顺序拼接形成融合特征。融合特征输入 LSTM 处理,最终通过线性层进行分类。




图 1 暴力行为监测模型结构

### 1.2 CDPP 模块

为优化模型训练效率并减少计算开销,本文设计了 CDPP 模块,如图 2 所示。




图 2 CDPP 模块

逐通道卷积 (Depthwise, DW) 层是 CDPP 模块核心部分,通过独立处理输入通道的方式,有效解决了传统卷积运算参数过多的问题,降低了计算成本和内存占用。之后,两个逐点卷积 (Pointwise, PW) 层协同工作:首层跨通道整合信息,并将这些特征信息重新组合成新的特征表示,以生成更具代表性的特征图;次层则进一步优化特征表达,提取更加抽象和复杂的特征,同时灵活控制特征维度和输出通道数。这种层级设计既保证了特征提取的深度,又实现了计算效率的显著提升。

## 2 实验设计与结果分析

### 2.1 数据集

实验选用 Fight Detection 和 RWF-2000 两个公开数据集进行模型验证。这两个数据集各包含 2 000 段采集自街道、公园等多样化公共场所的真实场景视频,以确保实验结果具有现实意义。所有视频片段均经过人工审核和标注,以保证数据质量符合实验需求。

### 2.2 对比实验

此文将与暴力检测领域中的现有模型进行比较,这些模型包括 ActionNet<sup>[8]</sup>、SlowFast<sup>[9]</sup>、CMDA (Cross-Modality Dual Attention)<sup>[10]</sup>、ViF (Violent Flows)<sup>[11]</sup>、ViF + OVIF (Optimized Violent Flows)<sup>[12]</sup>、Hough + CNN<sup>[13]</sup>、Stearns + LSTM、ResNet50 + NN (Neural Networks)<sup>[14]</sup>、FightNet<sup>[15]</sup>、Multi-frame 和 ConvLSTM。其结果如表 1 所示。

CDPP 模型在 RWF-2000 数据集上表现出显著的性能优势。其帧准确率为 98.33%,视频准确率为 98.81%,均高于其他模型。比表现次优的 Multi-frame 模型帧准确率高出 1.61%,视频准确率高出 0.97%,这表明 CDPP 模

型在处理复杂行为序列时表现出更好的鲁棒性。CDPP 模型的 GFLOPs 为 90,比大多数模型的计算复杂度都低。

为进一步评估模型的性能,本文在 Fight Detection 上进行对比实验,实验结果如表 2 所示。可以看到,相比于 RWF-2000 数据集上的准确率,模型在 Fight Detection 上的分类准确率要高得多。

2.3 消融实验

为验证 CDPP 模块的有效性,本文在 RWF-2000 数据集上设计了消融实验,实验结果如表 3 所示。本文选择 (Darknet + LSTM)模型作为实验的起点,并在 Darknet 和 LSTM 之间分别加入 CNN 模块和 CDPP 模块,以此来证明本文提出的 CDPP 模块的有效性。

表 1 在 RWF-2000 数据集上与现有方法的对比

| Model          | Frame Accuracy | Video Accuracy | GFLOPs |
|----------------|----------------|----------------|--------|
| ActionNet      | 0.826 9        | 0.835 3        | 73     |
| SlowFast       | 0.833 8        | 0.845 3        | 234    |
| CMDA           | 0.835 1        | 0.852 7        | 165    |
| ViF            | 0.814 8        | 0.829 4        | 94     |
| ViF + OViF     | 0.862 4        | 0.875 2        | 132    |
| Hough + CNN    | 0.927 8        | 0.946 1        | 48     |
| Stearns + LSTM | 0.921 7        | 0.939 7        | 214    |
| ResNet50 + NN  | 0.952 9        | 0.960 1        | 143    |
| FightNet       | 0.964 1        | 0.971 8        | 85     |
| Multi-frame    | 0.967 2        | 0.978 4        | 157    |
| ConvLSTM       | 0.761 2        | 0.772 6        | 98     |
| Ours           | 0.983 3        | 0.988 1        | 90     |

表 2 在 Fight Detection 数据集上与现有方法的对比

| Model          | Frame Accuracy | Video Accuracy | GFLOPs |
|----------------|----------------|----------------|--------|
| ActionNet      | 0.972 7        | 0.978 4        | 73     |
| SlowFast       | 0.977 4        | 0.985 1        | 234    |
| CMDA           | 0.972 5        | 0.980 4        | 165    |
| ViF            | 0.829 1        | 0.847 3        | 94     |
| ViF + OViF     | 0.881 4        | 0.898 2        | 132    |
| Hough + CNN    | 0.951 6        | 0.957 2        | 48     |
| Stearns + LSTM | 0.948 3        | 0.958 4        | 214    |
| ResNet50 + NN  | 0.967 2        | 0.975 6        | 143    |
| FightNet       | 0.971 1        | 0.978 1        | 85     |
| Multi-frame    | 0.973 4        | 0.986 2        | 157    |
| ConvLSTM       | 0.945 9        | 0.979 1        | 98     |
| Ours           | 0.987 1        | 0.991 5        | 90     |

表 3 使用不同模块在 RWF-2000 数据集上的准确率

| Model          | Module | Accuracy | GFLOPs |
|----------------|--------|----------|--------|
| Darknet + LSTM | None   | 0.961 7  | 71     |
| Darknet + LSTM | CNN    | 0.979 1  | 126    |
| Ours           | CDPP   | 0.988 1  | 90     |

根据表 3 数据可知,基线模型 Darknet + LSTM 的准确率为 96.17%,GFLOPs 为 71,这表明基础架构已经能够取得较好的性能,但仍有提升空间。引入 CNN 模块后,准确率提升至 97.91%,但 GFLOPs 增加至 126,说明引入 CNN 模块增强了特征提取能力的同时增加了模型的计算复杂度。引入 CDPP 模块后,模型的准确率进一步提升至

98.33%,而GFLOPs降低至90,这表明CDPP模块不仅进一步提高了准确率,还降低了计算复杂度和参数量。

### 3 结 语

现有的视频分类方法存在计算复杂度高、运算量大的问题。针对以上问题,文章提出了基于可分离卷积的CDPP模块。CDPP模块通过优化卷积结构,在提取图像深层次特征的同时降低模型参数量,提升计算效率。文章提出的方法在两个公开数据集上进行了实验,结果表明本文提出的方法能有效提高模型的训练效率,并能提升分类的准确率。消融实验结果显示,文章所提出的模块在增强多尺度特征融合能力的同时,优化了计算效率。未来的研究将聚焦于复杂场景下的视频分类任务,特别是遮挡情况下的暴力视频检测,以进一步拓展该方法的应用潜力。

### 参考文献

- [1] Dong Z, Qin J, Wang Y. Multi-stream deep networks for person to person violence detection in videos[C]//Chinese Conference on Pattern Recognition, November 5-7, 2016, Chengdu, China. Singapore: Springer Singapore, 2016:517-531.
- [2] Sudhakaran S, Lanz O. Learning to detect violent videos using convolutional long short-term memory [C]//2017 14th IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS). IEEE, 2017:1-6.
- [3] Liang Q, Li Y, Yang K, et al. Long-term recurrent convolutional network violent behaviour recognition with attention mechanism [J]. MATEC Web of Conferences, 2021, 336(01):5013.
- [4] Islam Z, Rukonuzzaman M, Ahmed R, et al. Efficient two-stream network for violence detection using separable convolutional lstm[C]//2021 International Joint Conference on Neural Networks(IJCNN). IEEE, 2021:1-8.
- [5] Hanson A, Pnvr K, Krishnagopal S, et al. Bidirectional convolutional lstm for the detection of violence in videos [C]//Proceedings of the European Conference on Computer Vision(ECCV) Workshops, 2018:280-295.
- [6] Asad M, Yang J, He J, et al. Multi-frame feature-fusion-based model for violence detection [J]. The Visual Computer, 2021, 37(06):1415-1431.
- [7] Traoré A, Akhloufi M. 2D bidirectional gated recurrent unit convolutional neural networks for end-to-end violence detection in videos [C]//International Conference on Image Analysis and Recognition. Cham: Springer International Publishing, 2020:152-160.
- [8] Wang Z, She Q, Smolic A. Action-net: multipath excitation for action recognition[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2021:13214-13223.
- [9] Feichtenhofer C, Fan H, Malik J, et al. Slowfast networks for video recognition[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2019:6202-6211.
- [10] Wei D, Tian Y, Wei L, et al. Efficient dual attention SlowFast networks for video action recognition[J]. Computer Vision and Image Understanding, 2022, 222:7.
- [11] Hassner T, Itcher Y, Kliper-Gross O. Violent flows: real-time detection of violent crowd behavior[C]//2012 IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops. IEEE, 2012:1-6.
- [12] Gao Y, Liu H, Sun X, et al. Violence detection using oriented violent flows [J]. Image and Vision Computing, 2016, 48:37-41.
- [13] Serrano I, Deniz O, Espinosa-Aranda J, et al. Fight recognition in video using hough forests and 2D convolutional neural network[J]. IEEE Transactions on Image Processing, 2018, 27(10):4787-4797.
- [14] Honarjoo N, Abdari A, Mansouri A. Violence detection using pre-trained models [C]//2021 5th International Conference on Pattern Recognition and Image Analysis(IPRIA). IEEE, 2021:1-4.
- [15] Zhou P, Ding Q, Luo H, et al. Violent interaction detection in video based on deep learning [C]//Journal of Physics: Conference Series. IOP Publishing, 2017, 844(01):12044.